

2025 高教社杯 C 题问题 1 建模报告

摘要

本文分析男胎 NIPT 记录中 Y 染色体浓度与检测孕周、孕妇 BMI 及其他个体因素的关系。数据包含 1082 条检测记录和 267 位孕妇，每位孕妇记录数中位数为 4，因此采用纵向重复测量框架。固定效应分布层使用 Beta 回归，以自然样条描述孕周、BMI 和年龄，并预设孕周-BMI 低秩张量交互；纵向方差层在同一设计矩阵上以 REML 估计孕妇随机截距和随机孕周斜率。新孕妇的 Y 浓度达到题目给定 4% 阈值的概率通过随机效应边缘化得到，并用单调分位数回归作辅助核验。

孕周与 Y 浓度呈弱正相关 (Pearson $r = 0.127$, $p < 0.001$)，BMI 与 Y 浓度呈弱负相关 ($r = -0.151$, $p < 0.001$)。Beta 似然比检验支持孕周、BMI、年龄与 IVF 项，但没有支持预设的孕周-BMI 交互 ($p = 0.766$ ；删除交互后 AIC 改善 12.26)。平均孕周处 ICC 为 0.809，说明个体异质性必须纳入；技术重复的 logit 尺度测量误差标准差为 0.133。GC 连续协变量、胎儿健康记录处理、孕周窗口和日期核验的概率敏感性均小于 0.035；分位数反演与 Beta 边缘概率最大差异为 0.150，提示尾部分布结论应保守解释。

常量说明：本文的临床浓度阈值始终是 **4%**。图中的 **95%** 仅表示统计置信区间；概率图中的 90% 水平线只用于演示反演，不是题目给定常量。

1. 数据与研究范围

分析对象来自 附件.xlsx 的“男胎检测数据”工作表。代码没有仅依赖工作表名称，而是进一步要求孕妇代码、Y 染色体浓度和 Y 染色体 Z 值均有效，并要求 $0 < Y < 1$ 。完整的数据处理逻辑见 solution.py，研究路线见图 1。





表 1 汇总了主要数据特征。原始 Y 浓度范围为 1.000%--23.422%，没有 0、1 或缺失边界，因此主模型无需零膨胀或边界修正。Shapiro-Wilk 检验 $p = 8.19 \times 10^{-15}$ ，否定原始 Y 浓度的正态性。145 条记录低于 4%，占 13.40%。

指标	结果
检测记录数	1082
孕妇数	267
每位孕妇记录数中位数	4
低于 4% 的记录	145 (13.40%)
技术重复	40 组、101 条
胎儿不健康记录	38
GC < 40%	451
日期反推孕周与文本孕周差异 > 1 周	144

图 2 显示纵向重复、孕周日期交叉核验和 BMI 分布。144 条日期核验差异较大的记录不在主分析中机械剔除，而是在敏感性分析中单独检验，避免因日期字段误差造成选择偏差。逐行核验日志见 [ga_crosscheck.csv](#)。



2. 模型


2.1 两阶段 Beta-GAMM

对第 i 位孕妇第 j 次检测的 Y 浓度 Y_{ij} ，设

$$Y_{ij} \sim \text{Beta}(\mu_{ij}\phi, (1 - \mu_{ij})\phi),$$

$$\text{logit}(\mu_{ij}) = \beta_0 + s_1(GA_{ij}) + s_2(BMI_{ij}) + ti(GA_{ij}, BMI_{ij}) + s_3(Age_i) + \beta_{IVF}IVF_i + b_{0i} + b_{1i}(GA_{ij} - \bar{GA}).$$

其中 $(b_{0i}, b_{1i})^\top \sim N(0, \Sigma_b)$ 。允许的 Python 库没有联合 Beta-GAMM 求解器，因此代码采用可审计的两阶段估计：
`statsmodels.othermod.betareg.BetaModel` 估计 Beta 均值和精度层，`MixedLM` 在相同固定效应设计矩阵上以 REML 估计随机效应方差层。该实现保留了 Beta 有界响应和纵向相关两项核心结构，但固定效应和随机效应不是联合极大似然估计，这是本文的首要方法限制。模型组成和边缘化原理见图 3。



2.2 达标概率


条件概率令随机效应为 0：

$$P_{cond} = P(Y \geq 0.04 \mid b_0 = b_1 = 0).$$

面向新孕妇的边缘概率为

$$P_{marg} = \int P(Y \geq 0.04 \mid b) f(b; 0, \Sigma_b) db,$$

代码用固定随机种子下的 400 次 Monte-Carlo 抽样计算。阈值在原始数据中的位置及逐孕周观察达标比例见图 4。




2.3 分位数辅助模型


辅助模型在 $\text{logit}(Y)$ 尺度拟合 $\tau = 0.05, 0.10, \dots, 0.95$ 的分位数回归，不放入孕周-BMI 交互。预测网格依次投影为：随孕周不减、随 BMI 不增、随 τ 不减，从而消除分位数交叉。阈值反演得到 $P_Q = 1 - \tau_*$ ，只用于交叉验证 Beta 边缘概率，不替代主模型。

3. 原始关系与固定效应结果

图 5 以六边形聚合散点展示原始关系，避免 1082 个点严重重叠。孕周与 Y 浓度为弱正相关，BMI 与 Y 浓度为弱负相关；弱边缘相关并不排除非线性和组内相关。



不同 BMI 四分位水平下的 Beta 均值曲线见图 6，二维预测面见图 7。曲线只在 10--25 周内解释。由于交互项未通过检验，图 7 应视为预设交互模型的描述性预测面，而不是交互效应已确证的证据。







表 2 给出 Beta 似然比检验。这里的 edf 是设计矩阵基函数维数近似，不是惩罚样条的精确有效自由度。

项	edf	LR	p 值	删除该项的 ΔAIC	结论
$s_1(GA)$	6	58.905	<0.001	46.905	显著
$s_2(BMI)$	6	43.799	<0.001	31.799	显著
$ti(GA, BMI)$	9	5.740	0.766	-12.260	未获支持
$s_3(Age)$	4	16.321	0.0026	8.321	显著
IVF	1	4.516	0.0336	2.516	显著

完整表见 [table_smooth_terms.csv](#)。孕周与交互基之间的最大近似 concavity 分别为 0.862 和 0.843，因此交互结论必须结合删除项 AIC 和敏感性曲线，不应只看单一 Wald 系数。VIF 与 concavity 结果分别见 [table_collinearity.csv](#) 和 [table_concurvity.csv](#)。

4. 模型比较与随机效应

同一 Beta 分布族内，无交互样条模型 AIC 最低；预设交互模型 $\Delta AIC=12.260$ 。GA 分段模型和线性模型的分组交叉验证 RMSE 分别为 0.0328 和 0.0331，优于未经惩罚的高维样条模型。这个结果说明现有样本不足以支持复杂交互作为稳健预测器。Beta 与 logit-Gaussian 模型的 AIC 不跨分布族比较，模型比较以同族 AIC和按孕妇分组的预测误差为准。




BMI 表达形式的 AIC 优于仅体重或身高+体重，后两者 ΔAIC 分别为 22.74 和 21.90。加入孕次与产产后 AIC 从 -4491.70 上升到 -4489.90，故主模型保留年龄与 IVF，但不加入孕产次。详细结果见 [table_covariate_forms.csv](#) 和 [table_parity_candidates.csv](#)。

随机截距方差为 0.1874，随机孕周斜率方差为 0.00140，平均孕周处 ICC 为 0.809。随机斜率的 Wald 区间包含 0，但根据预设纵向结构仍保留。条件预测与边缘预测在代表性网格上的差异为 0.061--0.089，说明令随机效应为 0 会系统性高估新孕妇达标概率。完整方差表见 [table_random_effects.csv](#)，量化网格见 [table_sens_marginal.csv](#)。

5. 达标概率与分位数反演


图 9 显示三个 BMI 四分位水平下的条件概率和边缘概率。边缘曲线不是单调上升：数据支持 15--16 周附近上升、19--20 周附近回落、随后再上升的形态。由于未经惩罚的样条在分组交叉验证中表现不佳，该局部起伏不宜直接解释为生理机制。



若仅把 90% 当作演示目标，BMI=30.21 的边缘概率最早在约 24.1 周达到 0.90；BMI=31.81 和 33.93 的曲线在 10--25 周内均未达到 0.90。这不是问题 2 的最佳检测时点结论，因为本题问题 1 不进行风险损失优化。


单调分位数族见图 10。12、16、20、24 周的分位数反演与 Beta 边缘概率绝对差为 0.027--0.150，最大差异出现在 BMI=33.93、20 周。该差异说明尾部概率对分布假设敏感，后续时点优化应进行保守校准。逐点比较见 [table_quantile_check.csv](#)。

中心BMI=31.8下的单调条件分位数族




6. 诊断与敏感性分析

Beta 随机分位数残差的 Q-Q 图整体接近直线，但孕妇层平均残差仍有离散，符合显著组内异质性的判断（图 11）。




基维数敏感性中， $k = 8$ 的 AIC 最低， $k = 5$ 与其相差 18.92， $k = 10$ 相差 5.38。为控制运行时间和高维交互的方差，主报告保留任务架构中的 $k = 5$ ，同时完整披露 `table_k_sensitivity.csv`。这也进一步说明需要在可用联合 GAMM 软件中复核平滑惩罚。


图 12--17 分别检验分布假设、交互、GC、边缘化、孕周窗口和日期核验；图 18 检验是否剔除胎儿不健康记录。




GC处理敏感性 (不采用硬阈值剔除)





个体随机效应积分的影响



孕周建模窗口敏感性





各敏感性曲线相对主分析的最大概率变化为：GC 0.00043，交互 0.0286，10--25 周窗口 0.0344，日期核验 0.0252，胎儿健康记录 0.0141。GC 的影响极小，支持“不按 40%--60% 硬阈值删除 451 条低于 40% 的记录”。相应审计表见

[table_sens_gc.csv](#)、[table_sens_ga_window.csv](#)、[table_sens_ga_crosscheck.csv](#) 和 [table_sens_health.csv](#)。

7. 结论

1. 孕周与 Y 浓度存在统计显著但较弱的正相关，BMI 存在统计显著的负相关；年龄和 IVF 在 Beta 固定效应层也有贡献。
2. 个体异质性远大于技术重复误差，ICC=0.809；面向新孕妇必须使用边缘概率，不能把随机效应设为 0 的条件曲线当作群体结论。
3. 数据没有支持预设的孕周-BMI 交互，且复杂样条的分组交叉验证不及分段/线性基准。交互预测面保留为预设模型描述，但后续决策模型应优先采用更简约并经过校准的概率模型。
4. GC 连续调整、孕周窗口、日期核验和胎儿健康记录处理对主概率曲线影响较小；分位数尾部反演差异较大，是更重要的不确定性来源。
5. 本问题只输出关系模型、达标概率、阈值反演和测量误差，不给出 BMI 分组或最佳 NIPT 时点；这些属于问题 2/3 的风险优化阶段。

8. 局限性与复现

- 两阶段 Beta-GAMM 不是固定效应与随机效应的联合似然估计；随机效应区间为近似 Wald/边界区间。
- 样条尚未通过联合 Beta-GAMM 的 REML 平滑惩罚估计，复杂曲线的局部起伏可能是过拟合。
- 数据来自高 BMI 为主的单地区样本，不能直接外推到一般孕妇群体；10--25 周之外只描述、不推断。
- 分位数模型的单调性通过预测网格投影实现，不是对原始分位数系数的全局约束优化。
- 90% 概率线没有临床规范含义，仅演示阈值反演；任何临床决策都需结合后续风险函数和外部验证。

复现命令：

```
$env:MODELING_DATA_PATH = (Resolve-Path '.\附件.xlsx').Path
$env:MODELING_OUTPUT_DIR = (Get-Location).Path
python .\solution.py
python .\figures.py
```

实测 `solution.py` 用时约 4.3 秒，`figures.py` 用时约 25.0 秒，总计约 29.3 秒，低于 90 秒约束。主结果长表为 `output.csv`，包含 54 行且列名、数值范围和行数均通过结果契约检查。原始附件与派生结果均在本仓库公开，未使用外部个人可识别信息，也未引入外部文献事实作为本报告结论依据。