

问题2：BMI分组与最佳NIPT时点的风险优化

摘要

本文使用问题1筛选得到的1082条男胎NIPT记录和267位孕妇，研究BMI分组与最佳检测时点。每位孕妇以多次记录的BMI中位数作为分组变量。概率层重新拟合孕周分段线性Beta模型，并用随机截距和中心化孕周随机斜率描述重复测量；对新孕妇的达标概率通过随机效应边缘化获得。决策层以

$$\ell(t; b) = \rho\{1 - p_{\text{marg}}(t, b)\} + r_{\text{delay}}(t), \quad \rho = 1,$$

作为综合损失，在10--25周内优化，并用动态规划进行连续BMI监督分箱。检测误差通过logit浓度测量误差和孕妇层cluster bootstrap双通道传播。

动态规划得到的圆整边界为BMI=30.0 kg/m²。但两组最优时点分别为12.024周与12.034周，差异仅0.011周，远小于预设0.5周可报告门槛；增加到3--6组仍不能产生有意义的时点差异。因此，本题最重要的结论不是“不同BMI必须使用不同日期”，而是：**BMI显著影响达标概率，但在当前损失标定下，数据支持所有BMI组统一在约12周检测**。孕妇层bootstrap与技术误差合并后的95%时点范围约为12.0--12.4周。`sigma_tech=0.133`仅使最优时点移动约0.003周，却使联合假阴性/假阳性概率升至约1.8%--2.7%，故实际应用应报告时点窗口并允许复检，不应把小数孕周解释成临床精度。

1 数据、假设与技术路线

数据解析严格遵循任务约束：孕妇代码去除字母A后转数值，末次月经转日期，检测孕周按“周数+天数/7”解析；染色体非整倍体字段完成去T字符的数值核验，但不进入问题2决策。分析单位由记录层聚合为孕妇层：


$$b_i = \text{median}_j(BMI_{ij}), \quad i = 1, \dots, 267.$$

题目唯一浓度阈值固定为

$$y_{\text{thr}} = 0.04.$$

完整流程见图1：先拟合简约概率模型，再计算边缘达标概率，构造不达标与延迟风险，最后联合完成动态分箱、误差传播、校准和敏感性分析。

问题2技术路线：从边缘达标概率到BMI分组与风险最优时点



2 简约Beta混合概率模型

2.1 模型形式

令第 i 位孕妇第 j 次检测的Y染色体浓度为 Y_{ij} ，则

$$Y_{ij} \sim \text{Beta}(\mu_{ij}\phi, (1 - \mu_{ij})\phi),$$

$$\text{logit}(\mu_{ij}) = \beta_0 + \beta_1 GA_{ij} + \beta_2 (GA_{ij} - 12.5)_+ + \beta_3 (GA_{ij} - 20)_+ + \beta_4 b_i + \beta_5 Age_i + \beta_6 IVF_i + b_{0i} + b_{1i}(GA_{ij} - \bar{GA}).$$

其中 $(b_{0i}, b_{1i})^\top \sim N(0, \Sigma_b)$ 。由于允许的Python库没有联合Beta混合模型求解器，实现采用两阶段近似：Beta回归估计固定效应和精度，MixedLM以REML估计随机效应协方差。该限制贯穿全部解释。

2.2 固定效应形式选择

按孕妇分组五折交叉验证保证同一孕妇不同时出现在训练集和验证集。

固定效应形式	CV RMSE	CV MAE	选择
孕周分段线性（12.5、20周节点）	0.03275	0.02623	是
纯线性	0.03301	0.02654	否

分段模型的RMSE略低，且与任务预设一致，故进入主决策。完整表见[tab_q2_model_selection.csv](#)。

固定效应估计中，BMI系数为 -0.03118 ， $p = 3.09 \times 10^{-12}$ ，说明控制孕周、年龄与IVF后，BMI越高，Y浓度均值越低。模型精度参数为 $\hat{\phi} = 66.84$ ；随机截距方差为0.1883，随机孕周斜率方差为0.00133。参数表和方差表分别见[tab_q2_model_coefficients.csv](#)与[tab_q2_random_effects.csv](#)。


2.3 边缘达标概率

问题2面对的是新孕妇，不能令随机效应等于0。因此固定 $Age = \bar{Age}$ 、 $IVF = 0$ 后计算

$$p_{\text{marg}}(t, b) = E_{b_i} [1 - F_{\text{Beta}}(0.04; \text{logit}^{-1}\{\eta(t, b, b_i)\}, \phi)] .$$

主分析使用1000次固定种子Monte-Carlo抽样。为满足90秒运行限制，Beta生存函数先在768点logit查找表上求值，再对每个MC样本插值；15个审计点与直接特殊函数计算的最大绝对误差仅 7.05×10^{-7} ，见[q2_probability_interpolation_audit.csv](#)。

图2显示，BMI中位数为29.2的G1组在整个孕周区间的达标概率均高于BMI中位数为32.7的G2组。局部回落来自12.5与20周分段斜率估计，不能解释为个体胎儿浓度必然下降。



3 风险损失与最佳时点


延迟风险按题目三档语义连续化：

$$r_{\text{delay}}(t) = \begin{cases} 0, & t \leq 12, \\ (t - 12)/15, & 12 < t \leq 27, \\ 3, & t \geq 28. \end{cases}$$

优化仅在题目允许的10--25周进行，28周后的极高风险尺度不参与优化。默认 $\rho = 1$ ，组损失为

$$L_k(t) = \rho\{1 - \bar{p}_k(t)\} + r_{\text{delay}}(t).$$

在0.1周网格上找到最小值后，以相邻三点抛物线细分。图3表明两个BMI组均在约12周达到最小损失；12周以后延迟风险的增加快于达标概率带来的损失下降。



4 BMI监督分箱

4.1 动态规划

将267位孕妇按 b_i 排序，以实际孕妇而非均匀BMI网格为分箱单元，求解

$$\min_{K, \{g_k\}} J = \sum_{k=1}^K n_k L_k(t_k^*),$$

约束为 $K \in \{2, \dots, 6\}$ 、 $n_k \geq 20$ 、BMI区间连续、边界圆整到0.5 kg/m²，并要求 $t_1^* \leq \dots \leq t_K^*$ 。个体时点若不单调，先用PAVA保序。

4.2 分组数选择


损失肘部初步位于 $K = 5$ ，但多分组只在总损失第四位小数后带来改善： $K = 2$ 时 $J = 56.0937$ ， $K = 6$ 时 $J = 56.0897$ ，相对改善不足0.01%。更重要的是，所有候选K的最大组时点跨度都不足0.022周，远低于0.5周可报告门槛。因此依据“不得硬造时点差异”的约束，选择最少允许的 $K = 2$ 。

组	BMI区间 (kg/m ²)	孕妇数	BMI中位数	数值最优周	合并误差95%区间	最优点达标概率
G1	[20.703, 30.0)	61	29.20	12.024	11.956--12.379	0.834
G2	[30.0, 46.875]	206	32.68	12.034	11.960--12.429	0.780

两组时点仅差0.011周，故主结果表中的distinct_required=False。小数孕周只用于复现优化器；临床/竞赛表达应统一写为：

两组均建议约12周检测；考虑不确定性，执行窗口约12.0–12.4周。

图4同时展示个体原始时点、PAVA保序曲线、BMI=30边界与组时点。极高BMI尾部个体时点上升明显，但样本极少，不能据此给高BMI组另造一个显著更晚的统一时点。



完整主表见tab_q2_main_results.csv，K选择审计见tab_q2_k_selection.csv。

5 双通道误差传播


5.1 通道A：检测重复性误差

在logit浓度尺度加入

$$u \sim N(0, \sigma^2), \quad \sigma \in \{0, 0.5\sigma_{tech}, \sigma_{tech}, 2\sigma_{tech}\},$$

其中 $\sigma_{tech} = 0.133$ 。重新计算观察达标概率和组最优时点。图5显示， $\sigma = \sigma_{tech}$ 时G1、G2时点分别只移动0.0038和0.0030周，远小于一天。


测量误差对最优时点的直接偏移很小



小的最优点偏移不等于误差无影响。采用共享潜在分位数耦合估计阈值错分后，在 $\sigma = \sigma_{tech}$ 时：

- G1联合假阴性概率约2.07%，联合假阳性概率约1.85%；
- G2联合假阴性概率约2.74%，联合假阳性概率约1.81%；
- 在 $2\sigma_{tech}$ 时，两组联合假阴性概率升至约5.0%--5.5%。

图6说明测量误差的主要后果是增加4%阈值附近的错分，而不是显著移动损失函数的最小点。




5.2 通道B：参数与抽样不确定性

以孕妇为cluster重抽样，每次重新拟合简约Beta均值层、快速更新残差随机截距/斜率协方差、重新计算边缘概率和动态分箱，并叠加 σ_{tech} 。首次完整配置超过90秒，因此按任务允许的降级条款使用：

- bootstrap 60次（目标100次）；
- bootstrap孕周网格0.2周；
- 每副本48次固定种子误差MC；
- 主分析仍使用0.1周网格和1000次MC。


完整程序运行73.05秒。图7显示选定 $K = 2$ 时BMI边界的bootstrap分布；30.0 kg/m²边界的精确重现频率约41.7%，边界不算稳定。因此BMI=30更适合作为描述性风险分层界点，而不是不可变的临床截点。



6 内部校准验证

首次观测即达到4%的孕妇比例为81.27%，说明观察到的首次达标时间存在严重左截尾，故不以生存分析作为主模型。内部校准比较首次观测达标比例与相应孕周、BMI下的模型边缘概率。

BMI组校准误差绝对值均不超过0.016；11--12周带的模型概率低估观察比例约0.084；15--20周带误差约0.165，但该带只有3位孕妇，不能据此判定系统失准。图8用点面积编码样本量，直观提示小样本校准点的不稳定性。




该校准使用同一数据，只能说明内部一致性，不是独立外部验证。

7 敏感性分析

7.1 主观损失比

ρ 是最重要的可解释决策参数。随着不达标损失相对延迟损失增大，推荐时点变晚： $\rho = 0.25$ 时约11.97周， $\rho = 1$ 时约12.03周， $\rho = 2$ 时约12.48周， $\rho = 4$ 时约12.51周；两个BMI组始终接近。

主观损失比越高，推荐时点越晚



7.2 模型来源和关键假设

不同概率来源得到的组时点为：简约分段Beta混合模型约12.02--12.03周，问题1无交互样条约12.00周，分位数反演约12.45周。含孕周--BMI交互样条可使某组时点偏移最多约1.37周，但问题1交互项似然比检验 $p = 0.766$ ，因此只作为不稳定上界，不进入主决策。

其他主要敏感性结果如下：

- 纯线性替代分段模型：最大时点变化0.074周；
- 条件概率替代边缘概率：最大变化0.139周；
- 延迟风险阈值从12周改为13周：最大变化0.524周；
- $\rho = 4$ ：最大变化0.488周；
- 剔除日期孕周差异最大的20条：最大变化约0.420周且边界改变；
- 剔除组内Y跳变大于0.05的32位孕妇：最大变化约0.422周且边界改变；
- 剔除不健康记录：最大变化0.003周；
- 加入GC连续协变量：最大变化0.006周。

结果说明，默认“约12周统一检测”在固定效应形式、GC与健康记录处理中稳定，但对延迟风险标定、数据质量尾部处理和不受支持的复杂交互较敏感。完整结果见[tab_q2_sensitivity_key_assumptions.csv](#)、[tab_q2_sensitivity_bins.csv](#)和[q2_probability_source_sensitivity.csv](#)。

8 结论与建议

1. BMI对Y染色体浓度达标概率有明确负向作用；BMI高组在相同孕周下达标概率更低。
2. 以BMI=30.0 kg/m²可形成两个连续描述性风险组，但边界bootstrap重现频率只有41.7%，不应把该切点视为固定临床常数。
3. 默认 $\rho = 1$ 和连续延迟风险下，两组最优时点差异仅0.011周，`distinct_required=False`，数据支持统一约12周检测。
4. 合并抽样与检测误差后的时点区间约12.0--12.4周。报告小数周只为算法复现，不代表临床可执行精度。
5. 技术测量误差几乎不移动最优点，却明显增加阈值错分；接近4%的单次结果应结合复检窗口判断。
6. 若实际机构认为不达标损失更高， $\rho = 2$ 的敏感性结果支持把统一时点推迟到约12.5周。最终应用应由临床成本确定 ρ ，而不是由模型自行赋予医学含义。

9 方法限制

- 模型是Beta固定效应与REML方差层的两阶段近似，不是联合似然Beta混合模型。
- bootstrap因90秒契约降为60次和0.2周网格，区间尾部分位数仍有Monte-Carlo不确定性。
- 内部校准不是外部验证，且15--20周首次观测带只有3位孕妇。
- BMI极低和极高尾部样本稀疏，个体时点外推不稳定。
- 延迟风险函数与 ρ 是决策假设，不是由当前观察数据识别出的临床效用参数。
- 分箱边界不稳定且组时点无实质差异，因此本文不把BMI=30解释成医学诊断界值。